

朱堃煌

18060990375 | kunhuang_zhu@163.com

主页: github.com/Hniii98

教育经历

福建理工大学	2021.09 – 2024.07
硕士 计算机技术（人工智能方向） 计算机科学与数学学院	
厦门理工学院	2016.09 – 2020.07
本科 计算机科学与技术 计算机与信息工程学院	

开源贡献

PyCUDA Windows CUDA 13.x 兼容性修复	PR #498 已合并
• 为 PyCUDA 上游贡献运行时兼容性修复：优化 DLL 搜索路径解析策略，新增 bin/x64 优先探测与旧版 bin 自动回退，保障跨版本 CUDA 环境下驱动动态库可靠加载。	

项目经历

未名 HPC × LCPU AI Infra 训练营

GPU 算子开发与 FlashKDA 优化

代码: [Assignment 1](#) | [Tensor Core & Pipeline](#) | [Team 分析](#) | [Team 挑战](#) | [fused_vtile](#)

报告: [Assignment 1 writeup](#) | [Tensor Core & Pipeline writeup](#) | [Team writeup](#) | [B300 Benchmark](#)

- GPU 编程（手写）**: 手写 CUDA、Triton 与 TileLang 算子，调优矩阵乘分块与流水级数；在 RTX PRO 6000 的指定测试中，Triton 吞吐达到 234.7 TFLOPS，约为同组 cuBLAS 基线的 99.7%。
- 算子开发（手写）**: 手写 Tensor Core GEMM、TMA 供数与多级流水线，完成融合 RMSNorm 与 NVFP4 量化；在 B300 的报告测试形状下，相对调优后的两步基线获得约 1.31–1.71× 加速。
- 性能分析（Agent 完成）**: 使用 Agent 完成 FlashKDA 基准复现、Nsight Compute/SASS 分析与微基准实验，定位状态递推、寄存器溢出和低精度数值范围问题，评估 tcgen05、value 分片及 CHUNK32 rescale 方案。
- FlashKDA 加速（Agent 实现）**: 使用 Agent 实现 fused_vtile 的 VTile Direct 融合前向内核；在 B300、 $T = 8192$ 、 $H = 64/96$ 、 $D = 128$ 的六组定长/变长测试中，相对原 K1/K2 实现加速 2.17–3.13×； $H = 96$ 定长耗时由 1.7049 ms 降至 0.6328 ms (2.69×)。
- 优化验证（Agent 完成）**: 完成 51 项融合内核测试，按 $\text{atol} = \text{rtol} = 10^{-2}$ 与 torch/K1/K2/FLA 参考对拍，覆盖状态、尾块和 CUDA Graph 回放；27 个原生 eager/graph 用例通过 Compute Sanitizer memcheck，内存错误为 0。

大模型基础组件与 FlashAttention-2

2026.04 – 2026.08

代码: [cs336_assignment1](#) | [assignment2-systems](#)

- BPE 核心**: 从零实现并行预分词、字节级词表训练与 Tokenizer；通过 pair → pre-token 倒排索引增量维护相邻对计数，将每轮合并的计数更新由全量 $O(N)$ 扫描缩减为仅遍历受影响 pre-token。
- 基础组件**: 实现 Transformer LM 核心模块、交叉熵与 AdamW，完成模型参数量、激活显存和训练 FLOPs 核算。
- FlashAttention-2**: 以 PyTorch 与 Triton 实现分块 Online Softmax 前向及 dQ/dK/dV 反向，无需显式存储 $N \times N$ 注意力矩阵，将中间显存复杂度由 $O(N^2)$ 降至 $O(Nd)$ 。
- 通信原语**: 从零实现 DDP、优化器状态分片与轻量级 FSDP，通过异步 All-Reduce、跨层权重 All-Gather 预取和梯度 Reduce-Scatter 实现计算通信重叠及分布式训练显存优化。

MiniTorch 深度学习框架与训练系统

2026.01 – 2026.04

代码: [CUDA 编程](#) | [MiniTorch 框架](#) | [Transformer 架构](#) | [Transformer CUDA 加速](#) | [分布式训练与并行](#)

- 框架实现**: 从零补全计算图拓扑排序与反向传播、Tensor 算子、Linear/MLP、损失函数和训练评估流程，并扩展支持多头注意力与 Transformer。

- **CUDA 加速**: 实现融合 Attention Softmax 与 LayerNorm 前后向 CUDA Kernel 并接入 Transformer; 相较基础实现分别获得约 $6.5 \times / 5.5 \times$ 、 $15.8 \times / 3.7 \times$ 加速, 端到端训练提速约 $1.1 \times$ 。
- **数据并行**: 基于 torch.distributed 与多进程实现数据无重叠切分、双卡进程组和逐参数 All-Reduce 梯度平均; 双卡训练时间及吞吐提升达到约 $1.5 \times$ 。

一生一芯 RISC-V 系统与自主 NPC 处理器

2025.05 – 2026.01

代码: [Hniii98/ysyx-workbench](#) 学号: ysyx_25040128, 已通过 C 阶段考核 ([查询](#))

- **系统基础**: 完成 Linux/C、Verilator 与数字电路实践; 实现支持 RV32IM 的 NEMU、AM 运行时与基础设施, 覆盖设备 I/O、异常处理及 RT-Thread 运行。
- **自主 NPC**: 独立使用 Verilog 实现单周期 RV32E NPC, 完成 PC、译码、ALU、寄存器堆、访存、写回及 CSR 模块, 支持 ECALL/MRET 等系统指令。
- **验证工具链**: 基于 Verilator 与 DPI-C 构建仿真环境, 接入简易调试器、FTrace 和单步/批量执行; 以 NEMU 为参考模型进行逐指令差分测试。

学术成果

- **朱堃煌**, 孙博, 毛国君. 面向无人机图像场景的小目标检测模型 [J]. 计算机工程与应用, 2024, 60(15): 243–251. DOI: [10.3778/j.issn.1002-8331.2401-0209](#)。