朱堃煌

18060990375 | kunhuang_zhu@163.com
主页：hniii98.github.io

教育经历

福建理工大学 2021.09 – 2024.07
硕士　计算机技术（人工智能方向）　计算机科学与数学学院

厦门理工学院 2016.09 – 2020.07
本科　计算机科学与技术　计算机与信息工程学院

开源贡献

PyCUDA Windows CUDA 13.x 兼容性修复 PR #498 已合并

- 为 PyCUDA 上游贡献运行时兼容性修复：优化 DLL 搜索路径解析策略，新增 `bin/x64` 优先探测与旧版 `bin` 自动回退，保障跨版本 CUDA 环境下驱动动态库可靠加载。

项目经历

未名 HPC × LCPU AI Infra 训练营

GPU 算子开发与 FlashKDA 优化

代码：Assignment 1 | Tensor Core & Pipeline | Team 分析 | Team 挑战 | fused_vtile
报告：Assignment 1 writeup | Tensor Core & Pipeline writeup | Team writeup | B300 Benchmark

- **GPU 编程（手写）**：手写 CUDA、Triton 与 TileLang 算子，调优矩阵乘分块与流水级数；在 RTX PRO 6000 的指定测试中，Triton 吞吐达到 234.7 TFLOPS，约为同组 cuBLAS 基线的 99.7%。
- **算子开发（手写）**：手写 Tensor Core GEMM、TMA 供数与多级流水线，完成融合 RMSNorm 与 NVFP4 量化；在 B300 的报告测试形状下，相对调优后的两步基线获得约 1.31–1.71× 加速。
- **性能分析（Agent 完成）**：使用 Agent 完成 FlashKDA 基准复现、Nsight Compute/SASS 分析与微基准实验，定位状态递推、寄存器溢出和低精度数值范围问题，评估 tcgen05、value 分片及 CHUNK32 rescale 方案。
- **FlashKDA 加速（Agent 实现）**：使用 Agent 实现 fused_vtile 的 VTile Direct 融合前向内核；在 B300、$T = 8192$、$H = 64/96$、$D = 128$ 的六组定长/变长测试中，相对原 K1/K2 实现加速 2.17–3.13×；$H = 96$ 定长耗时由 1.7049 ms 降至 0.6328 ms（2.69×）。
- **优化验证（Agent 完成）**：完成 51 项融合内核测试，按 atol = rtol = 10^{-2} 与 torch/K1/K2/FLA 参考对拍，覆盖状态、尾块和 CUDA Graph 回放；27 个原生 eager/graph 用例通过 Compute Sanitizer memcheck，内存错误为 0。

大模型基础组件与 FlashAttention-2 2026.04 – 2026.08

代码：CS336 基础组件 | CS336 训练系统

- **BPE 核心**：从零实现并行预分词、字节级词表训练与 Tokenizer；通过 pair → pre-token 倒排索引增量维护相邻对计数，将每轮合并的计数更新由全量 $O(N)$ 扫描缩减为仅遍历受影响 pre-token。
- **基础组件**：实现 Transformer LM 核心模块、交叉熵与 AdamW，完成模型参数量、激活显存和训练 FLOPs 核算。
- **FlashAttention-2**：以 PyTorch 与 Triton 实现分块 Online Softmax 前向及 dQ/dK/dV 反向，无需显式存储 $N \times N$ 注意力矩阵，将中间显存复杂度由 $O(N^2)$ 降至 $O(Nd)$。
- **通信原语**：从零实现 DDP、优化器状态分片与轻量级 FSDP，通过异步 All-Reduce、跨层权重 All-Gather 预取和梯度 Reduce-Scatter 实现计算通信重叠及分布式训练显存优化。

MiniTorch 深度学习框架与训练系统 2026.01 – 2026.04

代码：CUDA 编程 | MiniTorch 框架 | Transformer 架构 | Transformer CUDA 加速 | 分布式训练与并行

- **框架实现**：从零补全计算图拓扑排序与反向传播、Tensor 算子、Linear/MLP、损失函数和训练评估流程，并扩展支持多头注意力与 Transformer。

- **CUDA 加速**：实现融合 Attention Softmax 与 LayerNorm 前后向 CUDA Kernel 并接入 Transformer；相较基础实现分别获得约 6.5 × /5.5×、15.8 × /3.7× 加速，端到端训练提速约 1.1×。
- **数据并行**：基于 torch.distributed 与多进程实现数据无重叠切分、双卡进程组和逐参数 All-Reduce 梯度平均；双卡训练时间及吞吐提升达到约 1.5×。

一生一芯 RISC-V 系统与自主 NPC 处理器 2025.05 – 2026.01

代码：Hniii98/ysyx-workbench　学号：ysyx_25040128，已通过 C 阶段考核（查询）

- **系统基础**：完成 Linux/C、Verilator 与数字电路实践；实现支持 RV32IM 的 NEMU、AM 运行时与基础设施，覆盖设备 I/O、异常处理及 RT-Thread 运行。
- **自主 NPC**：独立使用 Verilog 实现单周期 RV32E NPC，完成 PC、译码、ALU、寄存器堆、访存、写回及 CSR 模块，支持 ECALL/MRET 等系统指令。
- **验证工具链**：基于 Verilator 与 DPI-C 构建仿真环境，接入简易调试器、FTrace 和单步/批量执行；以 NEMU 为参考模型进行逐指令差分测试。

学术成果

- **朱堃煌**，孙博，毛国君．面向无人机图像场景的小目标检测模型 [J]．计算机工程与应用，2024，60(15)：243–251．DOI: 10.3778/j.issn.1002-8331.2401-0209。